

基于Spark与优化RoBERTa模型的高性能文本分类系统研究

摘要

随着大数据和人工智能技术的迅速发展，自然语言处理（NLP）在信息提取、情感分析和智能问答等领域的应用日益广泛。其中，文本分类作为 NLP 的核心任务之一，对于实现自动化文本理解具有重要意义。本文探讨了一种基于Spark分布式计算平台与RoBERTa预训练模型相结合的文本分类方法，并详细介绍了模型结构及其各个组成部分的功能。文中首先回顾了Apache Spark的核心特性和其在大数据处理方面的优势，随后深入解析了RoBERTa模型的技术细节，包括其相较于BERT的多项改进措施。基于此，提出并实现了包含BiLSTM层、注意力机制及前馈神经网络在内的增强型文本分类模型。实验部分采用了GLUE数据集中的SST-2子集进行验证，结果显示该模型在准确率、查准率、查全率和F1分数等指标上均表现出色，特别是在二分类情感分析任务中达到了**87.2%**的准确率。最后，通过消融实验确认了各组件对提升模型性能的贡献，并对未来的研究方向进行了展望。本研究为构建高性能、可扩展的文本分类系统提供了可行的技术方案。

关键词：spark，RoBERTa模型，自然语言处理，文本分类

目录

摘要	1
目录	2
1 引言.....	3
2 相关工作	3
2.1 基于SPARK的大规模文本处理技术	3
2.2 ROBERTA模型及其在文本分类中的应用	3
3 模型介绍	4
3.1 SPARK分布式计算	4
3.2 ROBERTA模型	5
4 实验分析	9
4.1 实验环境及参数设置	9
4.2 实验数据集.....	10
4.3 评估指标说明.....	10
4.4 实验结果	10
5 结束语.....	12
参考文献.....	14

1 引言

在信息爆炸的时代背景下，互联网上每天都会产生海量的文本数据，如新闻、评论、社交媒体内容等。如何从这些非结构化数据中快速提取有价值的信息，成为当前学术界和工业界共同关注的焦点。文本分类作为自然语言处理的基础任务之一，旨在根据文本内容自动将其划分到一个或多个预定义的类别中，其在垃圾邮件过滤、舆情监控、推荐系统等领域有着广泛应用。

近年来，随着深度学习的发展，特别是基于 Transformer 架构的预训练语言模型（如 BERT、RoBERTa 等）在多项自然语言理解任务中取得了突破性进展。RoBERTa 通过改进训练策略和优化语料库，进一步提升了模型性能，在多项基准测试中表现优异。然而，RoBERTa 模型参数量庞大，计算开销较高，难以直接应用于大规模文本数据的实时处理场景。

与此同时，面对日益增长的数据规模，传统的单机文本处理方式已无法满足高效计算的需求。Apache Spark 作为一种分布式计算框架，具备良好的横向扩展能力，能够有效支持海量文本数据的并行处理。将 Spark 与深度学习模型相结合，不仅有助于提升文本处理的效率，也为构建端到端的智能文本分类系统提供了新的思路。

因此，本文提出一种基于 Spark 的分布式文本处理框架，并在此基础上集成 RoBERTa 模型用于文本分类任务。同时，针对 RoBERTa 在实际部署中的瓶颈问题，本文设计了多种模型优化策略，以提升其推理效率与部署可行性。通过实验验证，所提方法在分类性能和系统效率方面均取得良好效果，为大规模文本分类任务提供了一种有效的解决方案。

2 相关工作

2.1 基于 Spark 的大规模文本处理技术

随着互联网和社交媒体的快速发展，文本数据呈现出爆炸式增长的趋势，传统单机环境下的文本处理方式已难以满足实时性和效率性的要求。Apache Spark 作为一种高效的分布式计算框架，因其内存计算能力、良好的容错机制以及对多种编程语言的支持，被广泛应用于大规模数据处理领域。

在自然语言处理任务中，Spark 常用于实现文本清洗、分词、向量化等预处理步骤，以及支持大规模数据下的高效模型训练与推理。例如蔡宇翔等人[1]基于 Spark MLlib 结合 TF-IDF 算法与 Word2Vec 模型，提出一种加权词向量文本表示方法，通过使用 TF-IDF 值作为词向量的权重，在 THUNews 数据集上提升了文本分类的准确率。胡健[2]在其研究中构建了基于 Spark 的并行数据预处理流程，利用 Ansj 进行中文分词，并结合 TF-IDF 实现特征提取，进一步通过 Spark 分布式训练朴素贝叶斯、SVM 和逻辑回归模型进行情感分析，实验结果表明在分布式环境下模型训练效率显著优于单机环境。

近年来，许多研究者尝试将 Spark 与深度学习框架相结合。如盛雪晨[3]则在研究中将 Spark 与 BERT 模型结合，提出一种高效的分布式文本分类方法，不仅提高了海量新闻数据的训练效率，还通过引入联邦学习和差分隐私机制有效保护了数据隐私，最终在实际系统部署中实现了高精度和高效率的文本分类。这些研究充分体现了 Spark 在 NLP 大规模数据处理与模型训练中的强大能力。

2.2 RoBERTa 模型及其在文本分类中的应用

Transformer 架构的提出标志着自然语言处理领域建模方法的一次重大革新，其中 BERT (Bidirectional Encoder Representations from Transformers) 作为最早被广泛应用的预训

练语言模型之一，发挥了重要作用。BERT利用双向注意力机制，在多项自然语言理解任务中取得了显著突破。

在此基础上，RoBERTa（Robustly Optimized BERT Pretraining Approach）对 BERT 的预训练策略进行了多项优化改进，包括取消下一句预测（NSP）任务、延长训练步数以及采用动态掩码机制等。这些改进使RoBERTa在GLUE基准测试中表现优于原始 BERT 模型，成为当前文本分类和语义理解任务中的主流模型之一。

在实际应用中，RoBERTa被广泛用于新闻分类、情感分析、有害文本识别、实体识别等多个任务场景。例如杨甲栋[4]等人在文献中针对多语言网页分类任务提出了一种参数微调框架alterAda，结合序列适配器与并行适配器，有效提升了XLM-RoBERTa在低质量数据下的分类性能，F1 分数相比多种方法均有提升。胡明捷[5]在其研究中构建了基于RoBERTa的双通道情感分析模型 MF-DC，并融合文本内容特征、词性特征与情感特征，结合Bi-GRU与DPCNN网络结构，提升了模型对长、短文本情感极性的识别精度。张新生[6]等人则提出一种RoBERTa与多任务学习融合的有害文本识别方法，通过共享编码器与单任务编码器分别提取通用与专属特征，显著提升了识别的准确率与召回率。香前等人[7]则采用RoBERTa-BiLSTM-CRF模型进行藏文新闻要素识别，在自建数据集上实现了 88.8% 的 F1 值，有效提升了藏文信息抽取的准确性。这些研究充分体现了RoBERTa在多种自然语言处理任务中的强大适应能力与优异表现。

尽管RoBERTa模型在分类精度上表现出色，但其参数量庞大、推理速度慢的问题限制了其在资源受限环境中的部署。因此，近年来研究人员提出了多种RoBERTa的优化方法。

模型压缩和剪枝是提升 RoBERTa 推理效率和部署可行性的关键手段之一。例如罗琛[8]等人在文献中提出了一种基于 RoBERTa 和知识蒸馏的用户评价情感分析模型，通过引入温度系数调整教师模型生成的软标签分布，并结合数据增强技术，将大型 RoBERTa 模型的知识迁移至轻量化学生模型中，成功降低了模型参数量，显著提升了推理速度，同时保持了 95% 以上的原始模型准确率。Muthineni等人[9]则在研究中探索了权重修剪与子网络识别等模型优化技术，提出利用RoBERTa和Electra中的核心子模型进行高效微调，在减少训练资源消耗和碳排放的同时，实现了对新任务的快速适配和性能保持。这些研究表明，通过对RoBERTa进行有效的模型压缩、剪枝与知识迁移，可以在保证模型性能的前提下大幅提升其在实际应用中的效率与可持续性。

综上所述，结合 Spark 的高效数据处理能力和 RoBERTa 的强大语义理解能力，并辅以适当的模型优化策略，有望构建一个高性能、可扩展的大规模文本分类系统。

3 模型介绍

3.1 Spark分布式计算

本文所采用的是基于Apache Spark和Apache MLlib构建的Spark NLP库，这是一个专注于自然语言处理（NLP）的强大工具库。Spark NLP不仅提供了完整的NLP处理管道，还内置了众多预先训练好的模型，这些模型覆盖了从基础的分词、词性标注到复杂的情感分析、命名实体识别等多个NLP任务。更重要的是，Spark NLP赋予了用户训练、自定义以及保存模型的能力，使得用户能够根据自己的具体需求，灵活调整和优化模型性能。这些特性共同为机器学习管道提供了简单易用、高性能且准确的NLP注释功能，使得这些管道不仅可以在单机上运行，还能轻松地在集群或其他机器上部署和扩展，满足分布式环境下的处理需求。

Apache Spark作为Spark NLP的底层支撑，是一个快速且通用的计算引擎，专为大规模

数据处理而设计。与Hadoop MapReduce类似，Spark同样起源于加州大学伯克利分校的AMP实验室，并开源供全球开发者使用。然而，Spark在处理数据的方式上有着显著的创新。它能够将Job的中间输出结果保存在内存中，避免了频繁的HDFS读写操作，从而大大提高了数据处理的效率。这一特性使得Spark在需要迭代运行MapReduce算法的数据挖掘和机器学习等领域中表现出色，成为这些领域的首选计算框架。

Spark框架的整体架构可以划分为五个核心模块如图3-1所示。其中，Spark Core是整个框架的基础与核心，提供了最基本的功能支持。而Spark SQL、Spark Streaming、GraphX以及MLlib等模块则是在Spark Core的基础上进行了扩展，分别针对结构化数据处理、实时数据流式计算、图计算以及机器学习等场景提供了专业的解决方案。例如，Spark SQL作为分布式SQL查询引擎，能够处理本地、HDFS以及Hive等多种数据源，为用户提供了熟悉且强大的SQL查询接口；MLlib则是Spark提供的机器学习算法库，涵盖了分类、回归、聚类等多种常用算法，为机器学习任务提供了便捷的实现途径。




图3-1 Spark框架图

此外，Spark还支持Standalone、YARN和Mesos三种部署模式，为用户提供了灵活的资源管理和调度选项。Standalone模式使用Spark自带的集群管理器，能够方便地在集群中启动Spark并利用集群资源进行计算；YARN则主要用于管理和分配集群中的资源，确保资源的高效利用；而Mesos作为一个通用的分布式系统内核，能够管理多种类型的资源，为Spark提供了更为广泛的资源支持。

3.2 RoBERTa模型

BERT (Bidirectional Encoder Representations from Transformers) 是 Google 于 2018 年提出的预训练语言模型，其核心是基于 Transformer 编码器的双向上下文理解能力。通过在大规模文本数据上进行无监督预训练，BERT 能够捕捉语言的深层语义关系，随后通过微调 (Fine-tuning) 适配各类自然语言处理 (NLP) 任务，如情感分析、问答系统、文本分类等。

RoBERTa模型除了继承BERT模型的优势外还在BERT模型的基础上进行优化，RoBERTa模型可以在词级别上获取句子完整的特征向量空间表示。也可以将文本的嵌入向量作为输入，有更好的泛化能力，RoBERTa模型大致结构如图3-2所示。




图3-2 RoBERTa模型结构图

相较于 BERT，RoBERTa在模型规模、算力和数据上进行了显著提升，同时训练方法和文本编码方面，RoBERTa 也有多项改进：

- 1) 它拥有更大的模型参数量，从论文所提及的训练时长来看，其使用 1024 块 V100 GPU 训练了 1 天；训练时采用了更大的 batch size，尝试范围从 256 到 8000 不等；
- 2) 使用了更多训练数据，涵盖 CC-NEWS 等在内的 160GB 纯文本，远超最初 BERT 训练所用的 16GB BookCorpus 数据集和英语维基百科。
- 3) 掉下一句预测（NSP）任务采用动态掩码，即每次输入序列时生成新的掩码模式，使模型能适应不同掩码策略、学习多样语言表征，而非像原版 BERT 那样在数据预处理期间执行一次掩码得到静态掩码；
- 4) 原版 BERT 使用字符级别的、大小为 30K 且经启发式分词规则预处理后学得 BPE 词汇，RoBERTa 则采用更大的 byte 级别 BPE 词汇表，包含 50K 的 subword 单元，且未对输入作额外预处理或分词。

于是本文提出基于Spark分布式架构构建的RoBERTa文本分类模型，即RoBERTa-BiLSTM-Attention模型，其整体结构如图3-3所示，模型由文本输入层、特征提取层、分类层和输出层组成。本文通过英文文本分类任务，使模型能够捕捉复杂的上下文依赖关系，提高了模型的泛用性，解决了模型在应用于英文文本时性能降低的问题。文本输入层负责将原始文本转化为适合RoBERTa处理的格式；任务编码层通过多层Transformer编码器捕捉文本的深层语义信息；分类层则利用 [CLS] 标记的隐藏状态进行分类；最后，输出层生成分类结果并计算损失，指导模型优化。




图3-3 RoBERTa-BiLSTM-Attention模型结构图

3.2.1 文本输入层

文本输入层作为模型与原始数据的接口，承担着数据预处理的关键任务，为后续各层处理奠定基础。其主要功能是将输入文本转化为富有语义的向量形式，以便进行后续的情感分析工作。RoBERTa模型作为预训练模型，能够对输入文本进行深度的特征提取和编码。通过多层 Transformer 编码器，RoBERTa 模型能够学习到丰富的语义信息，并将其编码成上下文 相关的词向量。

步骤一：进行分词操作，RoBERTa模型采用字节对编码（BPE）技术，这种技术巧妙地结合了字符级和子词级的表示方法。它能够将输入的句子分割成合适的单词或子词单元，既避免了过于细粒度的字符级表示导致的信息丢失，又克服了传统词级表示可能面临的未登录词问题。例如，对于一些新出现的词汇或专业术语，BPE可以通过组合已有的子词单元来表示，大大提高了模型的适应性。

步骤二：添加特殊标记。在每个输入序列的开头添加 [CLS] 标记，这个标记在整个文本序列的处理中起着至关重要的作用，它对应的最终隐藏状态向量将用于后续的分类任务，因为它融合了整个序列的信息。如果处理的是涉及两个句子的任务，还需要在两个句子之间添加 [SEP] 标记，以区分不同句子的边界。

步骤三：将结果转换为对应的词汇表ID，这些ID是RoBERTa模型能够理解和处理的数字形式，使得模型能够对文本进行进一步的计算和分析。例如，输入文本“我喜欢学习自然语言处理”，经过分词和转换后可能变为 [CLS] 我 喜欢 学习 自然 语言 处理 [SEP]，然后每个词会被精确映射到相应的词汇表ID，为后续模型处理提供标准化的输入。

3.2.2 特征提取层

特征提取层主要由双向长短期记忆网络（BiLSTM）层和注意力机制（Attention）层组成。BiLSTM是一种神经网络结构，专门用于处理序列数据，而注意力机制则有助于模型更好地理解序列中的重要信息。在RoBERTa-BiLSTM-Attention模型中，BiLSTM被用于对RoBERTa模型的输出进行进一步的序列建模。BiLSTM分别从前向和后向对RoBERTa的输出序列进行编码，并将两个方向的隐藏状态拼接在一起，以获得对整个序列的双向建模。这样的序列表示可以更好地捕捉文本中的长期依赖关系和上下文信息。该层通过多层Transformer编码器深入挖掘输入文本的深层次语义信息。

1、双向长短期记忆网络（BiLSTM）结构

BiLSTM 结构而言，每一个时点的数据都需经过双向 LSTM 的预先加工与后续操作中使用到的是两个独立且互补的过程——即向前看一步并逐步更新的过程是基于对给定文本的前缀信息来构建其内部的状态；相反地，逆着这个方向来看待问题则是以倒推的方式去理解该语句的信息内容从而生成相应的中间结果及最终的结果值。因此需要按照顺序依次执行以下步骤：(a) 从 $t=0$ 这个点上获取原始的数据；(b) 对这些初始化后的参数设置一些必要的约束条件以便于之后的运算能够顺利完成；(c) 在此基础上利用上述定义好的函数式分别求解，最后根据以上得出的所有要素综合考虑之后再进一步确定最后的预测标签。若假设输入序列为 $H = [h_1, h_2, \dots, h_T] \in \mathbb{R}^{T \times d}$ ，其中T是序列长度，d是每个词向量维度，则所涉及到的计算公式如下所示：

$$\vec{h}_t = LSTM(h_t, \vec{h}_{t-1}) \quad (1)$$

$$\overleftarrow{h}_t = LSTM(h_t, \overleftarrow{h}_{t+1}) \quad (2)$$

$$b_t = [\vec{h}_t; \overleftarrow{h}_t] \in \mathbb{R}^{2d} \quad (3)$$

其中 $\vec{h}_t$ 为正向LSTM输出， $\overleftarrow{h}_t$ 为反向LSTM输出， b_t 为拼接后的双向表示。随后我们可得到整个序列为 $B = [b_1, b_2, \dots, b_T] \in \mathbb{R}^{T \times 2d}$ 。

2、多头注意力机制

注意力机制是Transformer架构的关键创新之一，它通过计算查询（Q）、键（K）和值（V）之间的相似度分数来生成加权求和的结果。具体来说，模型会计算每个位置与其他所

有位置的相关性，然后根据这些相关性对值进行加权组合，从而捕捉到文本中不同部分之间的依赖关系。多头注意力机制则进一步增强了模型的理解能力，它允许模型从不同的角度捕捉信息。通过将自注意力机制并行地应用多次，每个头都关注不同的特征子空间，然后将各个头的输出进行拼接，经过线性变换后得到最终的注意力表示。BiLSTM 特征抽取模块里的出产出输出向量 h_1 到 h_A 合成矩阵 $H \in \mathbb{R}^{T \times d}$ 后成为多个头部注意力机制模块的输入数据，经过 h 种独特的线性转换就产生了 Q 、 K 、 V 三条序列，第 i 个注意力头的线性表示公式为：

$$Q = HW_i^Q \quad (4)$$

$$K = HW_i^K \quad (5)$$

$$V = HW_i^V \quad (6)$$

其中 W_i^Q, W_i^K, W_i^V 是科学系参数， d_K 是每个头的维度。

然后分别计算每个头的注意力得分，并将这些得分通过 **Softmax** 函数进行标准化处理，最后将标准化后的得分与对应的数值 V 相乘，得到加权后的数值。具体公式如下：

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_K}}\right)V \quad (7)$$

多头拼接与投影后我们可得以下结果：

$$MultiHead(Q, K, V) = Concat(head_1, head_2, \dots, head_h)W^0 \quad (8)$$

其中 h 是头的数量， $W^0 \in \mathbb{R}^{hd_K \times d}$ 是最终投影矩阵。

3、前馈神经网络

前馈神经网络则对每个位置的输出独立应用相同的线性变换和激活函数（如ReLU），进一步提取和转换特征。每一层Transformer编码器都依次执行这些操作，通过多层堆叠，模型能够逐步构建起对输入文本的丰富语义表示，为后续的分类任务提供有力的特征支持。对于每一个位置 t 的输入向量 $x_t \in \mathbb{R}^d$ ，前馈网络执行如下操作：

$$FFN(x_t) = \max(0, x_t W_1 + b_1) W_2 + b_2 \quad (10)$$

其中 $W_1 \in \mathbb{R}^{d \times d_{ff}}$ ， $W_2 \in \mathbb{R}^{d_{ff} \times d}$ 是权重矩阵； $b_1 \in \mathbb{R}^{d_{ff}}$ ， $b_2 \in \mathbb{R}^d$ 是偏置项； d_{ff} 是中间层维度（通常大于 d ，如2048）；

3.2.3 分类层

分类层位于RoBERTa编码器的顶部，其作用是根据任务需求对编码器提取的特征进行微调，以实现准确的文本分类。

对于文本分类任务，通常从[CLS]标记对应的最终隐藏状态中提取特征向量。这个特征向量融合了整个文本序列的信息，是文本语义的高度概括。然后，将提取的特征向量传递给一个全连接层（Fully Connected Layer, FC）进行分类。

全连接层通过学习权重矩阵和偏置向量，将特征向量映射到所需的类别数。例如，在一个二分类任务中，全连接层会将特征向量映射到两个维度的输出空间。最后，应用激活函数（如Softmax）对全连接层的输出进行处理，获得每个类别的概率分布。Softmax函数能够将输出值转换为概率形式，使得所有类别的概率之和为1，从而方便模型确定输入文本最可能所属的类别。其公式如下：

$$y = Softmax(W_f h_{[CLS]} + b_f) \quad (11)$$

其中 W_f 和 b_f 是全连接层的权重和偏置， $h_{[CLS]}$ 是[CLS]标记对应的隐藏状态向量

通过这种方式，分类层能够充分利用RoBERTa编码器提取的丰富语义特征，实现对文本的准确分类。

3.2.4 输出层

输出层作为模型的最终环节，负责生成具有实际意义的预测结果，并指导模型的优化。

对于分类任务，输出层会输出每个类别的概率分布，这个概率向量直观地展示了输入文本属于各个类别的可能性大小。例如，在一个新闻分类任务中，输出层可能会输出一个概率

向量,表明该新闻属于体育、科技、财经等不同类别的概率。若分类层输出的特征向量 $\mathbf{z} \in \mathbb{R}^C$,其中 C 是类别总数,则经过 Softmax 函数后得到的概率分布 $p=(p_1, p_2, \dots, p_C)$,表示输入属于各个类别的概率。其具体公式如下:

$$p_i = \text{Softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}, \quad i = 1, 2, \dots, C \quad (12)$$

同时,输出层还承担着损失计算的重要任务。通常使用交叉熵损失函数来衡量模型预测与真实标签之间的差异。我们真实标签 $\mathbf{y} \in \{0,1\}^C$ 是 one-hot 向量,即只有一个位置为 1,其余为 0;模型输出的概率分布为 $p=(p_1, p_2, \dots, p_C)$ 。则单个样本的交叉熵损失公式如下:

$$y = -\sum_{i=1}^C y_i \log(p_i) \quad (13)$$

交叉熵损失函数能够有效地评估模型预测的准确性,当模型的预测概率与真实标签越接近时,损失值越小。根据计算得到的损失值,模型会通过反向传播算法更新参数,不断调整模型的结构和权重,以逐步减小损失,提高模型的性能。通过这种不断迭代优化的过程,模型能够逐渐提高对大规模文本数据的分类准确率,实现对文本数据的有效管理和利用。

4 实验分析

4.1 实验环境及参数设置

本文实验采用以下云服务器运行 RoBERTa 预训练代码,具体的实验环境如表 4-1 所示。

参数名称	配置信息
操作系统	CentOS 7 64 位
PyTorch 版本	2.8.0.dev20250610+cu118
Python 版本	Python 版本
CUDA 可用	否
模型训练工具	Transformers4.39.3、TensorFlow/PyTorch API

表 4-1 实验环境配置

RoBERTa 的超参数对模型性能具有重要影响。为了获得最佳效果,在多次调试和验证的基础上,最终选定表 4-2 中的超参数值作为本实验所采用的配置。

参数名称	值
训练轮次	5
训练批次大小	32
学习率	3e-5
掩码概率	0.15
每个序列最大掩码词数	20
权重衰减	0.01
Adam优化器epsilon值	1e-6
梯度裁剪最大范数	1.0

表 4-2 超参数配置

在 RoBERTa 模型的训练过程中,epochs 数量对模型收敛性和训练效率有显著影响。因此,本文在不同 epochs 数量下进行了对比实验,并以验证集上的损失和准确率作为评估指标。最终选择最优 epochs 值为 5,确保模型在合理时间内达到较好的训练效果并避免过拟合。

4.2 实验数据集

本实验采用GLUE数据集，GLUE包含九项NLU任务，语言均为英语。GLUE九项任务涉及到自然语言推断、文本蕴含、情感分析、语义相似等多个任务。其任务分别是CoLA、SST-2、MRPC、STS-B、QQP、MNLI、QNLI、RTE、WNLI。大致可以分为三类，分别是单句任务，相似性和释义任务。本实验采用其中的单句任务数据集SST-2进行操作。

SST-2(The Stanford Sentiment Treebank, 斯坦福情感树库)，是一个单句子分类任务，包含电影评论中的句子和它们情感的人类注释。这项任务是给定句子的情感，类别分为两类正面情感(positive, 样本标签对应为1)和负面情感(negative, 样本标签对应为0)，并且只用句子级别的标签。也就是，本任务也是一个二分类任务，针对句子级别，分为正面和负面情感。该数据集样本个数如下，有训练集67350个，开发集873个，测试集1821个。

标签为1的是正面(positive)情感样例，例如：

- two central performances
- against shimmering cinematography that lends the setting the ethereal beauty of an asian landscape painting
- the situation in a well-balanced fashion
- at achieving the modest , crowd-pleasing goals it sets for itself
- a patient viewer

标签为0的是负面(negative)情感样例，例如：

- a transparently hypocritical work that feels as though it 's trying to set the women 's liberation movement back 20 years
- blood work is laughable in the solemnity with which it tries to pump life into overworked elements from eastwood 's dirty harry period .
- faced with the possibility that her life is meaningless , vapid and devoid of substance , in a movie that is definitely meaningless , vapid and devoid of substance
- this new jangle of noise , mayhem and stupidity must be a serious contender for the title .

4.3 评估指标说明

在本实验中采用查准率、查全率、F1 值和准确率作为评估标准。

查准率(Precision)是指模型预测为正类的样本中，真实为正类的比例，反映模型的预测可靠性，FP（假阳性）越少，精确率越高。其计算公式如下所示：

$$Precision = \frac{TP}{TP+FP} \quad (14)$$

查全率(Recall)是指模型预测中真实为正类的样本中，被模型正确预测的比例，反映模型的覆盖能力，FN（假阴性）越少，召回率越高。其计算公式如下所示：

$$Recall = \frac{TP}{TP+FN} \quad (15)$$

F1分数(F1 Score)是指精确率和召回率的调和平均值，平衡两者性能。其计算公式如下所示：

$$F1\ Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (16)$$

准确率(Accuracy)指模型所有预测正确的样本占总样本的比例。其公式如下所示：

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (17)$$

4.4 实验结果

为了验证本文提出的基于 Spark 分布式架构构建的 RoBERTa-BiLSTM-Attention 文本分类模型 在英文文本情感分类任务中的有效性，我们在 GLUE 数据集集中的 SST-2 子集上进行了训练与测试。实验中将训练集用于模型训练，开发集用于超参数调优，测试集用于最终性能评估。

4.4.1 实验结果展示

在完成 10 轮训练后，模型在 SST-2 测试集上的表现如下

指标	值
准确率（Accuracy）	87.2%
查准率（Precision）	76.7%
查全率（Recall）	92.1%
F1 分数（F1 Score）	86.1%

表 4-3 结果展示图

从以上结果可以看出，模型在二分类情感分析任务中取得了优异的性能表现，尤其在准确率和 F1 分数上均超过87%，说明模型具有良好的泛化能力和分类鲁棒性。




图 4-1 PR曲线图

图4-1展示了一个二分类模型的精确率-召回率（Precision-Recall, PR）曲线，平均精度（Average Precision, AP）值为0.89。曲线显示，当召回率较低时，精确率接近1，意味着模型在识别正面情感时非常准确。随着召回率的增加，精确率逐渐下降，但在召回率达到0.8左右时，精确率仍保持在0.8以上，表明模型在广泛的召回率范围内表现良好。曲线下方的阴影区域表示PR曲线下面积，即AP值，0.89的AP值显示模型在精确率和召回率之间取得了良好的平衡。




图 4-2 ROC曲线图

图4-2展示了接收器操作特性（ROC）曲线，用于评估二分类模型的性能。橙色实线为ROC曲线，描绘了不同阈值下真正率（TPR）与假正率（FPR）的关系，曲线越靠近左上角，模型性能越好。黑色虚线代表随机猜测的基准。曲线下面积（AUC）为0.86，表明模型具有较好的区分能力，因为AUC接近1意味着高性能，而接近0.5则接近随机猜测。整体来看，该模型在保持低假正率的同时实现了高真正率，

4.4.2 模型消融实验

为进一步验证各模块对整体性能的贡献，我们进行了模型组件的消融实验。具体设置如下：

模型配置	F1 (%)	Acc (%)
RoBERTa+FC	81.8%	82.1%
RoBERTa+BiLSTM+FC	85.3%	84.7%
RoBERTa+BiLSTM+Attention+FFN+FC	86.1%	87.2%

表 4-4 消融实验结果对比表

结果可以看出：**BiLSTM**的引入提升了模型对上下文信息的建模能力；**多头注意力机制**与**前馈神经网络**进一步增强了语义特征的提取与非线性表达；整体来看，完整的RoBERTa-BiLSTM-Attention模型比基础RoBERTa模型提升了约**5.1%**的准确率和**4.3%**的F1分数，显示出所提出结构的有效性。所有模型的实验结果如图4-3所示。由图可看出本文研究的模型在比较各种模型时，其准确度表现最佳，比其他模型性能都优秀。




图 4-3 消融实验结果对比柱形图

4.4.3 模型在不同数据集下应用

为进一步验证模型对不同数据集的作用，我将模型对不同数据集进行了分类预测。具体结果如下：

数据集	F1 (%)	Acc (%)
SST-2	86.1%	87.2%
CoLA	79.83%	70.97%
WNLI	68.45%	68.45%

表 4-5 数据集分类结果对比表

模型在SST-2情感分析任务上表现优异，F1和准确率均超过86%，适用于语义清晰、结构简单的文本分类。但是在WNLI语义推理任务上，模型表现较差，F1与准确率均为68.45%，可见其不能很好完成需深层语义理解的任务。整体表明，该模型适用于表层特征明显的任务，但在复杂语言理解任务中存在局限

5 结束语

本文详细介绍了一种基于Spark分布式计算框架和RoBERTa模型的文本分类解决方案，

该方案结合了Apache Spark的高效数据处理能力和RoBERTa强大的自然语言理解能力。通过引入BiLSTM和多头注意力机制，进一步增强了模型对上下文信息的理解和捕捉复杂语义关系的能力。实验结果表明，所提出的RoBERTa-BiLSTM-Attention模型在英文文本情感分析任务中表现优异，特别是在准确率和F1分数上取得了显著进步，展示了其在实际应用中的潜力。

尽管取得了一定成果，但在未来的工作中仍有许多改进空间。例如，可以尝试更多的预训练模型或优化现有的模型架构以提高性能；同时，针对不同语言和领域进行模型迁移学习也是一个值得探索的方向。此外，随着深度学习技术的发展，如何更有效地利用大规模数据集以及提升模型训练效率也将是我们关注的重点。

参考文献

- [1] 蔡宇翔,王佳斌,郑天华.Spark平台下基于加权词向量的文本分类方法[J].现代计算机,2022,28(03):25-30
- [2] 胡健.基于Spark的中文文本情感分析研究[D].景德镇陶瓷大学,2023.DOI:10.27191/d.cnki.gjdtc.2023.000089.
- [3] 盛雪晨.基于分布式机器学习的文本分类模型研究[D].南京邮电大学,2023.DOI:10.27251/d.cnki.gnjdc.2023.001245.
- [4] 杨甲栋,容晓峰.XLM-RoBERTa应用于多语言网页分类的微调策略研究[J].西安工业大学学报,2025,45(03):452-467.DOI:10.16185/j.jxatu.edu.cn.2025.03.203.
- [5] 胡明捷.基于RoBERTa的文本类情感分析方法研究[D].大连交通大学,2025.DOI:10.26990/d.cnki.gsltc.2025.000545.
- [6] 张新生,张颢洸等.基于RoBERTa-MTL融合语言特征的有害文本识别[J/OL].情报杂志,1-8[2025-07-13].<http://kns.cnki.net/kcms/detail/61.1167.G3.20250427.1423.013.html>.
- [7] 香前,才藏太,李措.基于RoBERTa-BiLSTM-CRF的藏文新闻要素识别[J].高原科学研究,2024,8(04):108-114.DOI:10.16249/j.cnki.2096-4617.2024.04.012.
- [8] 罗琛.基于RoBERTa和知识蒸馏的用户评价文本情感分析研究[D].江西理工大学,2024.DOI:10.27176/d.cnki.gnfyc.2024.000992.
- [9] Muthineni, P. R. (2024). *Optimizing LLMs: Harnessing core sub-models in transformers for efficient training on new tasks* (Order No. 31330827). . (3069423259). Retrieved from <https://www.proquest.com/dissertations-theses/optimizing-llms-harnessing-core-sub-models/docview/3069423259/se-2>
- [10] 杨宇飞,钱育蓉,公维军,等.大模型优化的BERT图文多模态情感分析[J/OL].计算机系统应用,1-8[2025-07-13].<https://doi.org/10.15888/j.cnki.csa.009923>.